

Status for norsk talegjenkjenning 2025

Ingerid Løyning Dale, Tita Ranveig Enstad, Marie Iversdatter Røsok

Dato: 06.06.2025

Formål

I 2022 ba Språkrådet Språkbanken ved Nasjonalbiblioteket om å gjennomføre en evaluering av talegjenkjenningssystemer for norsk for å kartlegge hvor gode disse systemene er på å transkribere norsk tale. Språkbanken utviklet et testsett med 10 timer lydmateriale og transkripsjoner spesifikt til dette formålet. Høsten 2023 gjennomførte vi den første evalueringen og i januar 2024 kom den første rapporten med resultater fra evalueringen.

Formålet med evalueringen er å teste hvor gode talegjenkjenningsmodellene er på å transkribere norsk tale og hva de fortsatt sliter med å transkribere riktig. Det er en prioritet å teste muntlig tale og forskjellige norske dialekter, og vi har sørget for en god del spontan tale og bred dialektvariasjon i testsettet. Samtidig vil vi teste modellene på forskjellige typer lydmateriale, og testsettet inneholder derfor en variasjon i type tale (spontan, forberedt, manus-lest) og opptaksforhold (stille, støyende, bakgrunnsmusikk osv.).

Det er også meningen å teste talegjenkjenningsmodeller flere ganger med det samme testsettet i årene fremover for å se utviklingen til modellene over tid. Dette er grunnen til at vi har laget et eget testsett spesifikt for dette formålet som ikke er delt åpent.

Denne rapporten presenterer resultatene av den 2. evalueringen, og omfatter talegjenkjenningsmodeller som er lansert eller oppdatert etter modellene i forrige evaluering.

Henvisning til 2024-rapporten og GitHub-repositorium

Den første rapporten fra 2024 beskriver mer utfyllende formålet med evalueringen, testsettet, modellarkitekturer for talegjenkjenning og kvalitetsmål, blant annet, og det er mye av det som står i forrige rapport som fortsatt er gjeldende og som vi derfor utelater her. Vi henviser til fjorårets rapport med sidetall på flere steder i denne rapporten.

2024-rapporten finner du her: https://www.nb.no/sbfil/dok/2024_talegjenkjenning.pdf

Vi kan ikke dele testsettet åpent, men vi deler ellers alt av kode for å kjøre talegjenkjenningsmodeller, regne ut metrikker og evaluere resultatene på GitHub.

GitHub-repositoriet finner du her: https://github.com/Sprakbanken/asr_eval

Om du har kommentarer eller tilbakemeldinger angående koden eller evalueringen, ta gjerne kontakt med oss på sprakbanken@nb.no.

Talegjenkjenningsmodellene i årets evaluering

I 2024-rapporten testet vi åtte talegjenkjenningsmodeller for bokmål og fem for nynorsk fra Google, Microsoft, OpenAI og Nasjonalbiblioteket. I år tester vi ti forskjellige modeller, hvor ni testes for bokmål og seks for nynorsk, fra de samme aktørene, samt Meta.

I denne delen beskriver vi modellene som er med i årets evaluering, utviklingen siden forrige evaluering, og sammenligningsgrunnlaget med fjorårets modeller. Tabell 1 har en oversikt over årets modeller med info om språk, tilgang, type transkripsjon (ordrett/ikke-ordrett), testdato og lenke til den relevante skytjenesten eller nettsiden til modellen på Huggingface.

Nasjonalbiblioteket

AI-labben ved Nasjonalbiblioteket har trent talegjenkjenningsmodeller for bokmål og nynorsk med både Wav2Vec2- og Whisper-teknologien.

Ved forrige evaluering testet vi to NB-Wav2Vec2-modeller, én for bokmål og én for nynorsk. Vi testet bokmålsmodellen som på det tidspunktet gjorde det best. Den fikk navnet *nb-wav2vec2-bokmål* i forrige rapport, mens den faktiske modellen har navnet *wav2vec2-large-voxrex-npsc-nst-bokmaal-fixed* og er fortsatt tilgjengelig på Huggingface¹. Siden da har AI-labben publisert en ny modell trent på mere data, *nb-wav2vec2-1b-bokmål-v2*, og det er denne vi tester i årets evaluering. Nynorskmodellen vi testet i forrige evaluering fikk navnet *nb-wav2vec2-nynorsk* i forrige rapport, mens modellens fulle navn er *nb-wav2vec2-1b-nynorsk*. Dette er fortsatt den beste NB-Wav2Vec2-modellen for nynorsk. Den har fått noen mindre oppdateringer siden sist og vi tester den derfor igjen i år. NB-Wav2Vec2-modellene gir ordrette transkripsjoner.

AI-labben har trent forskjellige varianter av NB-Whisper med forskjellig abstraksjonsnivå. NB-Whisper gir undertekstlignende transkripsjoner på linje med OpenAIs Whisper, NB-Whisper-verbatim gir ordrette transkripsjoner, og NB-Whisper-semantic gir korte, oppsummerende transkripsjoner av talen. Ved forrige evaluering var disse modellene publisert i betaversjoner, og vi testet large-versjonene av alle tre typene for både bokmål og nynorsk – seks til sammen. I februar 2024 lanserte AI-labben endelige versjoner av NB-Whisper og NB-Whisper-verbatim. Vi tester de lanserte versjonene *nb-whisper-large* og *nb-whisper-large-verbatim* for bokmål og nynorsk i årets evaluering. Det er kun gjort mindre endringer fra betaversjonene og vi forventer at årets modeller gjør det omtrent like godt som i fjor. NB-Whisper-semantic finnes fortsatt kun i betaversjon og er ikke inkludert i årets evaluering.

OpenAI

I forrige evaluering testet vi OpenAIs Whisper-modell *whisper-large* for bokmål og nynorsk. Etter den første Whisper-modellen har OpenAI lansert både versjon 2 og 3, i henholdsvis 2022 og 2023, og vi tester *whisper-large-v3* (*openai-whisper-large-v3* i Tabell 1) i årets evaluering for

¹ <https://huggingface.co/NbAiLab/wav2vec2-large-voxrex-npsc-nst-bokmaal-fixed>

både bokmål og nynorsk. Modellen har omtrent samme arkitektur som tidligere², men er trent på mere data.

Høsten 2024 lanserte OpenAI også modellen *whisper-large-v3-turbo* som er ment å transkribere raskere. Modellen har færre dekode-lag, som gjør den raskere enn tidligere modeller, men det kan gå på bekostning av transkripsjonskvaliteten. Vi tester denne (*openai-whisper-large-v3-turbo* i Tabell 1) for både bokmål og nynorsk i år. Den har ikke en ekvivalent å sammenligne med fra 2024, men det vil være relevant å sammenligne resultatene med ikke-turbo-motparten *openai-whisper-large-v3*. Vi forventer at *openai-whisper-large-v3-turbo* gjør det noe dårligere ettersom farten går på bekostning av kvaliteten. Begge modellene gir ikke-ordrette transkripsjoner.

Google

Vi testet to modeller som var tilgjengelige i skytjenesten Google Cloud i forrige evaluering. Den første var en klassisk talegjenkjenningsmodell som har vært tilgjengelig i Google Clouds Speech-to-Text-tjeneste i flere år, mens den andre, Universal Speech Model, var ny i Google Cloud i 2023. De fikk henholdsvis navnene *gcloud-long* og *usm* i fjorårets rapport.

Google Cloud gir i dag valget mellom API-ene *Speech-to-Text V1* og *Speech-to-Text V2*. Gjennom 2024 har Google oppdatert de klassiske talegjenkjenningsmodellene i V1 til nye modeller med Conformer Speech Model-teknologi³, og V1 gir nå tilgang til oppdaterte conformermodeller med modellidentifikatoren *latest_long*⁴. Vi tester denne i årets evaluering og har gitt den det forenklede navnet *gcloud*. Vi sammenligner den med *gcloud-long* fra i fjor og anser dette for å være en tilsvarende tjeneste i Google Cloud, men forventer bedre resultater i år ettersom den gamle, klassiske talegjenkjenningsmodellen er forkastet til fordel for en conformermodell.

Googles Universal Speech Model har fått det nye navnet Chirp siden forrige evaluering, og høsten 2024 lanserte Google Chirp 2⁵, som beskrives som en raskere modell med bedre nøyaktighet, uten at det er spesifisert akkurat hvilke forbedringer det er snakk om. Vi tester Chirp 2 i årets evaluering og sammenligner med *usm* fra i fjor. Chirp 2 er kun tilgjengelig i *Speech-to-Text V2*. Chirp-modellene baserer seg også på conformer-teknologien, og det er usikkert hva som er forskjellen på conformermodellen i V1 og Chirp 2 i V2, men ettersom det står i dokumentasjonen at Chirp 2 utelukkende er tilgjengelig i V2, må vi anta at det er forskjeller mellom V1-modellen og Chirp 2. Denne evalueringen viser også at de to modellene presterer forskjellig, og Chirp 2 får bedre resultater enn *gcloud*. Begge Google-modellene gir ordrette transkripsjoner.

² Modellen bruker 128 Mel frequency bins som spektrograminput i stedet for 80.

³ Conformer-navnet refererer til Convolution-augmented Transformer, som er en modellarkitektur for talegjenkjenning utviklet av Google og introdusert i 2020 (Gulati et al., 2020).

⁴ <https://cloud.google.com/speech-to-text/docs/latest-models>. Google tilbyr *latest_short* for korte opptak på mindre enn 60 sekunder og *latest_long* for opptak på over 60 sekunder. Vi har valgt *long*-versjonen til vår evaluering. Dette er i tråd med forrige evaluering hvor det var et tilsvarende valg mellom *long*- og *short*-modeller og hvor vi valgte *long*-versjonen.

⁵ https://cloud.google.com/speech-to-text/v2/docs/chirp_2-model

Microsoft

I forrige evaluering testet vi Microsoft Azures tale-til-tekst-tjeneste, Azure AI Speech, ved navnet *azure*. Det står beskrevet på Microsofts nettsider at Azure AI Speech oppdateres fortløpende⁶. Tjenesten har fått store og små oppdateringer i løpet av 2024, og vi inkluderer *azure* også i årets evaluering. Microsoft har ikke gjort noen større endringer ved modellarkitekturen eller lansert en ny modell, så vi anser dette som en oppdatert versjon av samme talegjenkjenningssystem som ved forrige evaluering. Azure gir ordrette transkripsjoner.

Meta

Metas Massively Multilingual Speech-prosjekt⁷ kombinerer Wav2Vec2-teknologien med data for over tusen språk, og i 2023 publiserte de den flerspråklige modellen *mms-1b-all* som ifølge Meta kan transkribere mer enn 1100 språk. Denne modellen (*facebook-mms-1b-all* i Tabell 1) ble ikke testet i forrige evaluering. Vi inkluderer den i årets evaluering, men resultatene gjør det tydelig at den ble utelatt fra forrige rapport på grunn av den svært dårlige kvaliteten. Modellen gir ordrette transkripsjoner.

Tabell 1: Talegjenkjenningsmodellene vi tester i årets evaluering

Aktør	Navn	Språk	Tilgang	Ordrett/ ikke-ordrett	Lenke til modell	Testdato
Nasjonal- biblioteket	nb-whisper-large	bokmål	åpen	ikke-ordrett	Huggingface	27.12.24
		nynorsk				27.12.24
	nb-whisper-large- verbatim	bokmål	åpen	ordrett	Huggingface	22.01.25
		nynorsk				22.01.25
	nb-wav2vec2-1b- bokmål-v2	bokmål	åpen	ordrett	Huggingface	21.01.25
	nb-wav2vec2-1b- nynorsk	nynorsk	åpen	ordrett	Huggingface	23.12.24
OpenAI	openai-whisper- large-v3	bokmål	åpen	ikke-ordrett	Huggingface	10.02.25
		nynorsk				09.02.25
	openai-whisper- large-v3-turbo	bokmål	åpen	ikke-ordrett	Huggingface	24.12.24
		nynorsk				11.02.25
Google	chirp_2	bokmål	betaling	ordrett	Google cloud	09.02.25
	gcloud	bokmål	betaling	ordrett		30.12.24
Microsoft	azure	bokmål	betaling	ordrett	Azure AI Speech	07.03.25
Meta	facebook-mms- 1b-all	bokmål	åpen	ordrett	Huggingface	21.01.25
		nynorsk				21.01.25

⁶ <https://learn.microsoft.com/en-us/azure/ai-services/speech-service/releasenotes?tabs=speech-sdk>

⁷ <https://ai.meta.com/blog/multilingual-model-speech-recognition/>

Modellarkitektur

I forrige rapport beskrev vi hvordan modellarkitekturen har utviklet seg vekk fra klassiske, modulære talegjenkjenningsmodeller de siste årene (Solberg et al., 2024, s. 7-9). Det har ikke vært noen store nyvinninger innen modellarkitekturer siden forrige evaluering, men det kan være verdt å nevne at *openai-whisper-large-v3-turbo* er en videreutvikling av Whisper-teknologien der antallet dekode-lag er redusert fra 32 til 4, hvilket gjør modellen mindre og raskere. I tillegg har Google som nevnt byttet ut en gammel Google Cloud-modell til fordel for en conformermodell.

Datasett

I fjor rapporterte vi hvilke datasett for talegjenkjenning som finnes i Språkbankens ressurskatalog (Solberg et al., 2024, s. 5-7). Siden da har Språkbanken publisert et nytt datasett bestående av lyd og undertekster fra pressekonferanser, hentet fra Departementenes sikkerhets- og serviceorganisasjon (DSS). Tabell 2 har en oppdatert oversikt over datasett.

Tabell 2: Oversikt over datasett for norsk talegjenkjenning i Språkbankens ressurskatalog

Datasett	Størrelse i timer	Antall talere	Tale	Transkripsjon	Skrift-språk	Ressurs-katalogen
NST norsk ATG-database (16 kHz)	540	~1000	opplest	ordrett	bokmål	lenke
Stortingskorpuset 2.0	126	267	opplest, spontan	ordrett	bokmål, nynorsk	lenke
Stortinget Speech Corpus	5189	729	opplest, spontan	ikke-ordrett	bokmål, nynorsk	lenke
NB Samtale	24	69	spontan	ordrett	bokmål, nynorsk	lenke
Norsk talestyringskorpus	10	11	opplest, spontan	ordrett	bokmål, nynorsk	lenke
Pressekonferanser fra DSS	138	ukjent	opplest, spontan	ikke-ordrett	bokmål, nynorsk	lenke

Kvalitetsmål

Ordfeilrate (Word Error Rate, WER) og tegnfeilrate (Character Error Rate, CER) er tradisjonelle kvalitetsmål for å evaluere kvaliteten på talegjenkjenning. Disse metrikkene sammenligner prediksjonene (transkripsjonene modellene gir ut) med en referansetranskripsjon (testsettet) og teller antall feil ord eller tegn i prediksjonen for å gi et mål på hvor riktig transkripsjonen er. Disse metrikkene legger til grunn en ordrett transkripsjon der alt som sies blir transkribert for å kunne gi et godt mål på kvaliteten. En nærmere beskrivelse av WER- og CER-metrikkene er gitt i 2024-rapporten (Solberg et al., 2024, s. 19-20).

Ikke alle talegjenkjenningsmodellene gir ordrette transkripsjoner. Noen av modellene gir mer undertekstlignende transkripsjoner, og for disse er det ikke et mål at alle ordene er gjengitt nøyaktig i prediksjonen, men heller at meningsinnholdet i det som blir sagt er bevart. Da vil også

WER og CER være mindre gode kvalitetsmål, fordi vi forventer en forskjell i ord og tegn mellom referansen og prediksjonen.

For å måle kvaliteten til modellene som gir mindre ordrette transkripsjoner, bruker vi såkalte *embeddings*, som er vektorrepresentasjoner av tekstene vi vil sammenlikne. Vi lager én *embedding* for prediksjonen, og én for referansen, og bruker enkel vektorregning for å se hvor ulike de er. Dette målet kaller vi for semantisk avstand (Semantic Distance, SemDist). Det finnes *embedding*modeller som lager vektorer på både ord- og dokumentnivå.

Vi har regnet ut tre varianter av semantisk avstand, som vi beskriver kort:

- **SemDist**, slik det er beskrevet i Kim et al. (2021), bruker en *embedding*modell på ordnivå, og lager *embeddings* på dokumentnivå ved å regne ut gjennomsnittet på tvers av ord*embeddings*ene i teksten. I vårt testsett er dokumentene de individuelle setningene i testsettet. Vi har brukt BERT-modellen *nb-bert-large*⁸ for å lage ord*embeddings*, og regner ut setning*embeddings* i henhold til Kim et al. (2021) sin metode.
- **sBERT SemDist** er en variant av SemDist der vi bruker en *embedding*modell direkte på dokumentnivå for å komme frem til setningens vektorrepresentasjon. Metoden for å sammenligne *embedding*en til to tekster er den samme, men metoden for å komme fram til setning*embedding*en er altså annerledes. Vi har brukt sBERT-modellen *nb-sbert-base*⁹ for å lage *embeddings*ene. Dette er samme metode som vi brukte i fjor og som vi kalte SemDist i forrige evaluering (Solberg et al., 2024, s. 20-21). I år kaller vi dette målet sBERT SemDist for å skille det fra det originale SemDist-målet.
- **Aligned Semantic Distance (ASD)**, slik det er foreslått i Rugayan et al. (2022) er en alternativ måte å regne ut likheten mellom to tekster. Det tradisjonelle SemDist-målet kan påvirkes av setningslengde ved at noe av informasjonen viskes ut når man lager en gjennomsnittlig *embedding* på tvers av orda i en setning, og denne effekten er større for lengre setninger. Dette gir seg utslag i at betydningsforskjeller ved enkeltord får mindre å si når setninga er lang, som kan gi en kunstig god SemDist-score for lange setninger. ASD tar høyde for dette ved å gjøre en sammenstilling av orda i de to setningene som skal sammenlignes, og sammenligner vektorene på ordnivå for å komme frem til en overordnet score for hvor like eller ulike to setninger er.

Kvalitetsmål og normvariasjon

Det er stor normvariasjon i både bokmål og nynorsk, hvilket kan være problematisk når man regner ut WER og CER. Hvis prediksjonen inneholder en annen form av et ord enn referanse-transkripsjonen, vil det telle som feil selv om prediksjonen var en korrekt og akseptabel transkripsjon (f.eks. *å snakka* vs. *å snakke*, *bygge* vs. *byggje*, *fram* vs. *frem*). Dette kan føre til en forhøyet WER- og CER-score, hvilket er greit å ha i mente når man ser på resultatene. Det samme gjelder valg rundt hvorvidt gjentakelser og avbrytelser skal transkriberes. Hvis testsettet ikke inneholder gjentakelser av ord eller avbrutte ord, og prediksjonen gjør det, vil de ekstra

⁸ <https://huggingface.co/NbAiLab/nb-bert-large>

⁹ <https://huggingface.co/NbAiLab/nb-sbert-base>

ordene i prediksjonen telle som feil, selv om det kanskje var en god og nøyaktig gjengivelse av talen. I begge tilfeller kan SemDist-målene være med å nyansere bildet, og i større grad si noe om hvorvidt meningsinnholdet i to transkripsjoner er det samme til tross for at ordformene er ulike.

Ideelt sett vil vi ha en normaliseringsprosess der ord med flere tillatte former blir normalisert til samme form i både referanse og prediksjon slik at transkripsjonene kan sammenlignes på like fot (f.eks. *boken* = *bok*). Dette er vanskelig å få til for norsk der normvariasjonen er stor og ikke alltid forutsigbar, og vi har dessverre ikke fått implementert noe slikt i årets evaluering, men vi ønsker å se mer på mulighetene for å ta høyde for normvariasjonen i fremtiden.

Resultater

Tabell 3, 4, 5 og 6 inneholder resultatene for WER, CER, sBERT SemDist, SemDist og ASD for alle tategjenkjenningsmodellene fra i fjor og i år. WER og CER er gitt i prosent, mens SemDist, sBERT SemDist og ASD er gitt med desimaler mellom 0 og 1. Lavest prosent/desimal er alltid best resultat, men tallene er ikke sammenlignbare på tvers av metrikker for en gitt modell.

Tabell 3: Resultater for bokmålsmodellene 2024

Navn	WER	CER	sBERT SemDist	SemDist	ASD
nb-whisper-large-bokmål	18,51 %	13,06 %	0,0789	0,0553	0,1888
nb-whisper-large-verbatim-bokmål	11,87 %	06,40 %	0,0760	0,0495	0,1647
nb-whisper-large-semantic-bokmål	31,26 %	24,33 %	0,0943	0,0770	0,2613
nb-wav2vec2-bokmål	22,06 %	11,71 %	0,1691	0,1017	0,3309
openai-whisper-large-bokmål	29,70 %	17,89 %	0,1820	0,1106	0,3892
usm	20,65 %	12,61 %	0,1592	0,1113	0,2888
gcloud-long	30,18 %	21,98 %	0,2474	0,1662	0,4113
azure	24,38 %	15,73 %	0,1430	0,0889	0,2781

Tabell 4: Resultater for nynorskmodellene 2024

Navn	WER	CER	sBERT SemDist	SemDist	ASD
nb-whisper-large-nynorsk	28,40 %	18,50 %	0,0944	0,0827	0,2393
nb-whisper-large-verbatim-nynorsk	20,55 %	10,01 %	0,0856	0,0703	0,2092
nb-whisper-large-semantic-nynorsk	35,14 %	25,87 %	0,0998	0,0918	0,2826
nb-wav2vec2-nynorsk	38,58 %	19,04 %	0,2420	0,1543	0,5111
openai-whisper-large-nynorsk	51,87 %	43,65 %	0,2591	0,2161	0,6559

Tabell 5: Resultater for bokmålsmodellene 2025

Navn	WER	CER	sBERT SemDist	SemDist	ASD
nb-whisper-large	18,06 %	12,60 %	0,0755	0,0535	0,1853
nb-whisper-large-verbatim	11,87 %	06,42 %	0,0749	0,0493	0,1638
nb-wav2vec2-1b-bokmål-v2	26,70 %	13,32 %	0,1964	0,1361	0,4293
openai-whisper-large-v3	21,82 %	12,71 %	0,1449	0,0887	0,3095
openai-whisper-large-v3-turbo	22,77 %	13,33 %	0,1639	0,1075	0,3649
chirp_2	20,50 %	12,52 %	0,1589	0,1111	0,2886
gcloud	28,20 %	19,70 %	0,2252	0,1482	0,3846
azure	24,32 %	15,70 %	0,1427	0,0889	0,2783
facebook-mms-1b-all	59,61 %	24,48 %	0,3895	0,2865	0,8742

Tabell 6: Resultater for nynorskmodellene 2025

Navn	WER	CER	sBERT SemDist	SemDist	ASD
nb-whisper-large	26,56 %	16,90 %	0,0902	0,0793	0,2365
nb-whisper-large-verbatim	19,95 %	09,78 %	0,0850	0,0691	0,2068
nb-wav2vec2-1b-nynorsk	42,30 %	20,16 %	0,2576	0,1763	0,6002
openai-whisper-large-v3	39,69 %	18,89 %	0,1761	0,1507	0,3910
openai-whisper-large-v3-turbo	42,41 %	20,33 %	0,1918	0,1720	0,4589
facebook-mms-1b-all	67,73 %	28,79 %	0,3993	0,3032	0,8823

Sammenligning av gamle og nye tall for 2024

Vi har som nevnt oppdatert koden for å regne ut metrikker og analysere resultatene, og vi har derfor evaluert fjorårets predikerte transkripsjoner med den oppdaterte koden, slik at sammenligningen med årets modeller blir på likt grunnlag. Vi ser av Tabell 3 og 4 at verdiene for WER, CER og sBERT SemDist er noe annerledes regnet ut med årets kode enn det som ble rapportert i fjor (se Vedlegg 1 for fjorårets tall). Dette er forventet på grunn av endringer ved hvordan utregningen av metrikkene håndterer tomt eller ugyldig input, samt utregning av gjennomsnittlig feilrate for hver modell. Koden for årets utregninger er tilgjengelig på [GitHub](#).

De oppdaterte verdiene er gjennomgående bedre for alle modellene og for alle metrikkene. Forskjellene er relativt små for WER og CER, og spenner fra å være 0,02 til 3,45 prosentpoeng bedre. Forskjellene er større hos nynorskmodellene, og det er *openai-whisper-large-nynorsk* som får størst forskjell. Forskjellene ved WER- og CER-tallene endrer ikke på rangeringen av modellene fra best til verst, men forblir den samme som rapportert i fjor.

Forskjellene mellom fjorårets og årets tall er større ved sBERT SemDist (bare SemDist i fjor), og forskjellen er størst hos modellene som i utgangspunktet hadde de dårligste tallene. Modellen som hadde dårligst score var *gcloud-long*, og den har følgelig også størst endring fra 0,38 til

0,25. Endringene i verdiene til sBERT SemDist-målet endrer også på modellenes rangering fra best til verst (se Vedlegg 1). Med fjorårets tall er den beste modellen for både bokmål og nynorsk *nb-whisper-large*. Med årets tall er det *nb-whisper-large-verbatim* som kommer best ut.

Sammenligning av semantisk avstand-metrikkene

SemDist (med BERT-modell) og ASD er nye mål i år. Det oppdaterte SemDist-målet gir lavere verdier enn sBERT SemDist og ASD, mens ASD gir høyere verdier enn de to andre. Dette er på grunn av utjevningseffekten vi beskrev under Kvalitetsmål. ASD prøver spesifikt å motvirke denne effekten og gir dermed høyere verdier.

Også her er det slik at forskjellen mellom SemDist, sBERT SemDist og ASD er minst for modellene med best score, og større for modellene med dårligst score, men det er verdt å merke at de forskjellige semantisk avstand-metrikkene ikke er direkte sammenlignbare, ettersom de er forskjellige metrikker med forskjellige utregningsmetoder.


Sammenligning av resultater 2024 og 2025

Når vi ser på resultatene for årets modeller i Tabell 5 og 6, ser vi at det er *nb-whisper-large-verbatim* som får de beste resultatene, og modellen gjør det gjennomgående best for alle metrikkene for både bokmål og nynorsk, fulgt av *nb-whisper-large*. De fleste modellene har større eller mindre forbedringer siden i fjor, og *openai-whisper-large-v3* viser størst forbedring for alle metrikkene sammenlignet med fjorårets OpenAI-modell. Unntakene er *nb-wav2vec2-1b-bokmål-v2* og *nb-wav2vec2-1b-nynorsk* som får dårligere resultater enn fjorårets modeller, mens *facebook-mms-1b-all*, som testes for første gang i år, peker seg ut med svært dårlige resultater.

Søylediagrammene i delkapitlene under grupperer og sammenligner bokmåls- og nynorskresultatene til fjorårets og årets modeller for å illustrere forskjellene mellom sammenlignbare modeller og endringen i deres prestasjoner fra i fjor til i år. Gruppene er gitt forenklede navn og består av modeller fra samme aktør som det er naturlig å se opp mot hverandre. Se Vedlegg 2 for en oversikt over hvilke modeller gruppene består av.

WER

Figur 1: WER for bokmåls- og nynorskmodellene 2024 og 2025



nb-whisper-large-verbatim og *nb-whisper-large* var modellene som fikk best WER-score i fjor, og disse modellene holder seg stabile og får best WER-score i år også. For bokmål har *nb-whisper-large-verbatim* samme score med 11,87 %, mens *nb-whisper-large* har en liten bedring fra 18,51 % til 18,06 %. For nynorsk har begge modellene en forbedring fra henholdsvis 20,55 % til 19,95 % og fra 28,4 % til 26,56 %.

azure og *Google-modellene* har også svært stabile resultater sammenlignet med tilsvarende modeller i fjor. *azure* og *chirp_2* reduserer WER med noen desimaler av et prosentpoeng til henholdsvis 24,32 % og 20,5 %, mens *gcloud* reduserer WER med et par prosentpoeng fra 30,18 % til 28,2 %. Som beskrevet over har Google byttet ut den gamle talegjenkjenningsmodellen med en conformermodell, så vi forventet bedre resultater for *gcloud*. Disse resultatene viser også at det er forskjell på modellene *chirp_2* og *gcloud*, og det er *chirp_2* som gjør det best.

openai-whisper-large-v3 er modellen med størst forbedring sammenlignet med *openai-whisper-large* i fjor, og reduserer WER fra 29,7 % til 21,82 % for bokmål og fra 51,87 % til 39,69 % for nynorsk. Den nye modellen *openai-whisper-large-turbo-v3* har resultater som ligger i samme landskap, med WER på 22,77 % for bokmål og 42,41 % for nynorsk. Som beskrevet tidligere er det forventet at modellen gjør det noe dårligere enn ikke-turbo-motparten, men


forskjellen på de to modellene er ikke veldig stor, og den gjør det bedre enn *openai-whisper-large* gjorde i fjor.

nb-wav2vec2-1b-bokmål-v2 og *nb-wav2vec2-1b-nynorsk* gjør det dårligere enn modellene vi testet i fjor. WER-scoren øker fra 22,06 % til 26,7 % for bokmålsmodellen, og fra 38,58 % til 42,3 % for nynorskmodellen.

facebook-mms-1b-all testes for første gang i år og får de desidert dårligste resultatene med WER på 59,61 % for bokmål og 67,73 % for nynorsk.

CER

Figur 2: CER for bokmåls- og nynorskmodellene 2024 og 2025



nb-whisper-large-verbatim får best CER-score i år som i fjor, med 6,42 % for bokmål og 9,78 % for nynorsk. *nb-whisper-large* reduserer CER fra 13,06 % til 12,6 % for bokmål og fra 18,5 % til 16,9 % for nynorsk. Modellen var nest best for nynorsk i fjor, og er det også i år, men den var fjerde best for bokmål i fjor, og med den reduserte CER-en hopper den opp til andre plass i år.

Resultatene for *azure*, *chirp_2* og *gcloud* har samme tendens som for WER. *azure* og *chirp_2* får omtrent lik CER som i fjor med henholdsvis 15,7 % og 12,52 %, mens *gcloud* reduserer CER med et par prosentpoeng fra 21,98 % til 19,7 %, og det er igjen slik at *chirp_2* gjør det bedre enn *gcloud*.


openai-whisper-large-v3 har størst forbedring også for CER. For bokmål reduseres CER fra 17,89 % til 12,72 %, mens for nynorsk reduseres CER fra 43,65 % til 18,89 %, hvilket betyr at andelen feil tegn mer enn halveres. Den nye modellen *openai-whisper-large-v3-turbo* får igjen litt dårligere resultater enn ikke-turbo-motparten – 13,33 % for bokmål og 20,33 % for nynorsk – men allikevel langt fra like dårlige resultater som *openai-whisper-large* fikk i fjor.

NB-Wav2Vec2-modellene får høyere CER i år enn i fjor. CER-scoren øker fra 11,71 % til 13,32 % for bokmål og fra 19,04 % til 20,16 % for nynorsk.

facebook-mms-1b-all får dårligst CER-score med 24,48 % for bokmål og 28,79 % for nynorsk.

sBERT SemDist

Figur 3: sBERT SemDist for bokmåls- og nynorskmodellene 2024 og 2025



nb-whisper-large-verbatim og *nb-whisper-large* får best sBERT SemDist-resultater. *nb-whisper-large-verbatim* får en score på 0,07 for bokmål og 0,09 for nynorsk, og *nb-whisper-large* får en score på 0,08 for bokmål og 0,09 for nynorsk. Modellene får omtrent like resultater som i fjor, men har en liten forbedring på noen få desimaler for både bokmål og nynorsk. I tillegg ser vi at resultatene til de to modellene er jevn gode med hverandre, hvilket stemmer overens med det vi så i fjor. Som en modell som gir ikke-ordrette transkripsjoner, får *nb-whisper-large* høyere WER- og CER-verdier, men modellene ser ut til å bevare meningsinnholdet i transkripsjonene omtrent like godt når man regner ut sBERT SemDist.

azure og *chirp_2* har også stabile resultater og får en score på henholdsvis 0,14 og 0,16, mens *gcloud* reduserer scoren fra 0,25 til 0,23.


openai-whisper-large-v3 har størst forbedring, fra 0,18 til 0,14 for bokmål og fra 0,26 til 0,18 for nynorsk, mens *openai-whisper-large-v3-turbo* får en score på 0,16 for bokmål og 0,19 for nynorsk.

NB-Wav2Vec2-modellene får dårligere resultater for dette målet også, hvilket tyder på at når prediksjonene nå inneholder en større andel feil ord og tegn, endrer det også meningsinnholdet i transkripsjonene slik at det går utover betydningslikheten. Scoren går opp fra 0,17 til 0,20 for *nb-wav2vec2-1b-bokmål-v2*, og fra 0,24 til 0,26 for *nb-wav2vec2-1b-nynorsk*.

facebook-mms-1b-all får dårligst resultater med 0,39 for bokmål og 0,40 for nynorsk.

SemDist

Figur 4: SemDist for bokmåls- og nynorskmodellene 2024 og 2025



SemDist-målet er en ny implementasjon med BERT-modell i år. Tendensen er allikevel den samme som for de andre metrikkene. *nb-whisper-large-verbatim* og *nb-whisper-large* får best score. Begge får 0,05 for bokmål, mens for nynorsk får den første 0,07 og den andre 0,08. Disse resultatene er omtrent like som for fjorårets prediksjoner.

azure og *chirp_2* får samme score som i fjor, henholdsvis 0,09 og 0,11, mens *gcloud* har en forbedring fra 0,17 til 0,15.


openai-whisper-large-v3 reduserer SemDist fra 0,11 til 0,09 for bokmål og fra 0,22 til 0,15 for nynorsk. *openai-whisper-large-v3-turbo* får en SemDist-score på 0,11 for bokmål og 0,17 for nynorsk.

nb-wav2vec2-1b-bokmål-v2 øker SemDist-scoren fra 0,10 til 0,14 og *nb-wav2vec2-1b-nynorsk* øker scoren fra 0,15 til 0,18.

facebook-mms-1b-all får en SemDist-score på 0,29 for bokmål og 0,30 for nynorsk.

ASD

Figur 5: ASD for bokmåls- og nynorskmodellene 2024 og 2025



ASD gir høyere verdier for alle modellene, og vi ser som sagt at forskjellen er større for modellene med dårligst score, hvilket fører til et større gap mellom beste og dårligste modell. De beste modellene er *nb-whisper-large-verbatim*, med en ASD-score på 0,16 for bokmål og 0,21 for nynorsk, og *nb-whisper-large*, med en ASD-score på 0,19 for bokmål og 0,24 for nynorsk.

azure og *chirp_2* har fortsatt stabile resultater med liten endring fra i fjor, og får en ASD-score på henholdsvis 0,28 og 0,29, mens *gcloud* reduserer scoren fra 0,41 til 0,39.

openai-whisper-large-v3 reduserer ASD-scoren fra 0,39 til 0,31 for bokmål og fra 0,66 til 0,39 for nynorsk, mens *openai-whisper-large-v3-turbo* ligger litt over med 0,36 for bokmål og 0,46 for nynorsk.

nb-wav2vec2-1b-bokmål-v2 øker scoren fra 0,33 til 0,43, og *nb-wav2vec2-1b-nynorsk* øker scoren fra 0,51 til 0,60.

facebook-mms-1b-all får dårligst score med 0,87 for bokmål og 0,88 for nynorsk.

Resultater for dialektområder, overlappende tale og kjønn

I den videre analysen ser vi nærmere på resultater for dialekt, overlappende tale og kjønn. Vi rapporterer kun WER i denne delen.


Dialektresultater

Alle talere i testsettet er annotert med dialekt slik at vi kan sammenligne resultatene på tvers av dialekter og se om det er noen dialekter modellene er bedre eller dårligere på å transkribere. Vi har delt dialektene inn i fem dialektområder: østnorsk, vestnorsk, sørvestnorsk, trøndersk og nordnorsk. Det er minst 1,5 timer tale for hvert dialektområde i testsettet, men det er ikke nøyaktig like mye tale for hvert dialektområde (se Vedlegg 3 for en oversikt over andelen materiale per dialekt). I fjorårets rapport så vi at dette påvirket dialektresultatene fordi dialektområdet med mest tale (østnorsk) inneholdt mer vanskelig lydmateriale, og fikk dermed tilsvarende dårlige resultater. Det viste seg at lydmateriale med mye overlappende tale var vanskelig for modellene. Vi rapporterer på dette i år også, men vil se at forklaringen må nyanseres noe.

Bokmål

Fjorårets rapport viste at østnorsk fikk dårligst WER-score for de fleste bokmålsmodellene. For modellene hvor østnorsk ikke fikk dårligst score, var det sørvestnorsk som fikk dårligst score, og ellers var hovedtrekkene at sørvestnorsk, vestnorsk og trøndersk lå et sted i mellomstaket, mens nordnorsk oftest fikk best score.

Figur 6: WER fordelt på dialektområder, bokmål




I årets evaluering ser vi lignende resultater. For de fleste modellene får østnorsk dårligst score og nordnorsk best score, mens sørvestnorsk, vestnorsk og trøndersk ligger et sted i mellomstektet. Dette gjelder for NB-Whisper-modellene, OpenAI-modellene, NB-Wav2Vec2-modellene og *gcloud*. Modellene som skiller seg ut er *chirp_2*, *azure* og *facebook-mms-1b-all*. For *chirp_2* har sørvestnorsk dårligst score og vestnorsk best score, og for *azure* har sørvestnorsk dårligst score, og østnorsk best score, og disse resultatene er parallelle med *usm* og *azure* i fjor hvor vi så det samme. *facebook-mms-1b-all* peker seg ut med dårligst resultater generelt, men her er tilfellet at sørvestnorsk og vestnorsk får dårligst score, mens trøndersk får best score.

Nynorsk

Dialektresultatene for nynorskmodellene var litt annerledes enn bokmålsresultatene i forrige evaluering. Det var tydelig at de nynorsknære dialektområdene vestnorsk og sørvestnorsk fikk best resultater, mens de andre dialektområdene ikke gjorde det like godt, og dette hang sammen med innblanding av bokmål i prediksjonene for de ikke-nynorsknære dialektene. Østnorsk og trøndersk var da dialektene som fikk dårligst resultater, mens nordnorsk lå midt på treet.

Figur 7: WER fordelt på dialektområder, nynorsk



I årets evaluering har dette bildet endret seg noe. Sørvestnorsk og vestnorsk får fortsatt best resultater for flere av modellene, men den nye modellen *openai-whisper-large-v3-turbo* har best resultat for nordnorsk, hvilket er det samme vi ser for *openai-whisper-large-v3* og som vi så for *openai-whisper-large* fjor, mens *facebook-mms-1b-all* har best resultat for trøndersk. Trøndersk får i år ikke dårligst resultat hos noen av modellene, mens østnorsk nå er dialekten med de dårligste resultatene hos alle modellene. Dette gjør at nynorskresultatene ligner mer på

bokmålsresultatene. Det er fortsatt de nynorsknære dialektene som gjør det best, men nordnorsk og trøndersk gjør det forholdsmessig litt bedre, mens østnorsk gjør det litt dårligere.


Det er allikevel fortsatt forskjeller mellom bokmåls- og nynorskresultatene som vi kan lese av varmekartene. Nynorsk har et tydeligere skille mellom radene, altså modellene, i varmekartet, mens bokmål har et blandet bilde der vi kan se skiller mellom både rader og kolonner i varmekartet. Det betyr f.eks. at NB-Whisper-modellene er gjennomgående bedre på nynorsk for alle dialektene, mens OpenAI-modellene er dårligere på nynorsk for alle dialektene. Det igjen taler for at resultatene henger sammen med modellenes evne til å produsere riktig nynorsk, og ikke i like stor grad hvor godt de forstår de forskjellige dialektene. For bokmålsresultatene er det en forskjell mellom modellene. For eksempel ser *chirp_2* ut til å håndtere dialektene forskjellig, mens *openai-whisper-large-v3* håndterer dialektene omtrent like godt.

Overlappende og ikke-overlappende tale


Fjorårets rapport konkluderte med at lydmaterialer med mye overlappende tale var utfordrende for modellene. Dette lyd materialet bidro til at østnorsk fikk spesielt dårlig score, og når vi sammenlignet WER for materiale med og uten overlappende tale så vi at det var en kvalitetsforskjell mellom kategoriene for alle modellene. Vi gjør samme analyse i år, men bryter også resultatene ned på dialekt. Hvis de dårlige østnorskresultatene kun har å gjøre med den store andelen overlappende tale, burde vi se at østnorsk gjør det bedre (relativt til de andre dialektene) når vi bare ser på materiale uten overlapp.

Figur 8 og 9 viser at materiale med overlappende tale fortsatt får høyere WER-verdier enn materiale uten overlapp. Materiale med overlapp utgjør ca. 10 % av testsettet, men får mellom 11 og 22 prosentpoeng høyere WER.

Figur 8: WER fordelt på overlappende og ikke-overlappende tale, bokmål



Figur 9: WER fordelt på overlappende og ikke-overlappende tale, nynorsk



Vedlegg 3 har en oversikt over andelen overlappende og ikke-overlappende tale for hver dialekt og for hele testsettet. Vedlegg 4 inneholder WER-verdiene for kategoriene overlappende og ikke-overlappende tale.


Dialektresultater for ikke-overlappende tale

Når vi går videre og ser på dialektresultatene for materialet uten overlappende tale i Figur 10 og 11, ser vi at resultatene er bedre med lavere WER-verdier enn for alt materialet samlet, og det er mindre forskjell mellom dialektene. Den eneste modellen hvor dette ikke stemmer like godt er *chirp_2*, som får omtrent like høy WER på den dårligste dialekten, sørvestnorsk. Det viser at denne modellen transkriberer sørvestnorsk dårlig, uavhengig av overlappende tale. Ellers viser bokmålsresultatene at forholdet mellom dialektene endrer seg, og østnorsk gjør det relativt sett bedre når vi tar det overlappende materialet ut av regnestykket. Det er nå sørvestnorsk som får de dårligste resultatene.

Det er allikevel ikke sånn at østnorsk hopper frem som den best gjenkjente dialekten så fort vi fjerner det overlappende materialet. Overlappende tale ser ut til å være én del av de kompliserende faktorene, men det kan være andre effekter som også spiller inn. Østnorsk er dialekten med størst andel i testsettet og et større sett vil ha større bredde i talere, stemmekvalitet, hvor tydelig man snakker, vokabular, omgivelser, mengde og type støy, romklang, opptakskvalitet m.m., og ikke minst forskjellige kombinasjoner av disse trekkene som kompliserer eller forenkler lydbildet. Et mindre sett vil romme mindre variasjon og være

mer ensformig. Vi har ikke annotert testsettet med ethvert tenkelig trekk, så det er vanskelig å si noe om hvilke andre trekk som spiller inn. Dessuten er det ikke en absolutt regel at dialektene med mye materiale får de dårligste resultatene og dialektene med mindre materiale får de beste resultatene. Sørvestnorsk er dialekten med minst materiale, men får som sagt dårligst resultater i Figur 10.

Figur 10: WER for ikke-overlappende tale fordelt på dialekt, bokmål



Det er også relevant å nevne at dialektvariasjonen innad i det østnorske dialektområdet ikke ser ut til å være en medvirkende faktor. Når vi tradisjonelt sett forventer best resultater for østnorsk, er det som oftest snakk om standard østnorsk (Solberg et al., 2023). I vårt testsett har vi delt dialektene inn i fem grove dialektområder, hvor østnorsk dekker et stort område og rommer mer enn bare standard østnorsk¹⁰. Standard østnorsk (Oslo og omegn) utgjør omtrent 80 % av det østlandske materialet, mens de fire andre dialektene utgjør 20 % av materialet, og vi har undersøkt om de øvrige dialektene bidrar til høye WER-verdier for østnorsk. Når vi ser på fordelingen i segmentene¹¹ med høy WER (WER over 80 %) er fordelingen omtrent lik, og ingen av de øvrige dialektene skiller seg ut med dårligere resultater enn Oslo-dialekten.


I nynorskresultatene for ikke-overlappende tale (Figur 11) ser vi en tydeligere tendens i favør av vestlandsdialektene. Nå får også OpenAI-modellene best resultater for enten sørvestnorsk eller vestnorsk. De øvrige dialektene scorer relativt sett dårligere og østnorsk forblir dialekten med dårligst resultater hos alle modellene. Resultatene til de ikke-nynorsknære dialektene ser i større grad ut til å henge sammen med kvaliteten på nynorsktranskripsjonene, heller enn

¹⁰ Østnorsk omfatter: Oslo og omegn (Oslo, Akershus, Vestfold, flatbygdene i Telemark og Buskerud), Innlandet, Midtlandsk (deler av Telemark, Numedal, Hallingdal, Valdres, Nord-Gudbrandsdal), Agder, Østfold.

¹¹ Det er 7260 segmenter i testsettet. Ett segment tilsvarer én setning fra en taler og har en assosiert lydfil og referansetranskripsjon.

effekten av overlappende tale, og vi mener at forklaringen står seg om at de nynorsknære dialektene får mer riktige nynorsktranskripsjoner, mens det blandes inn bokmål i de andre dialektene (se Eksempler fra utvalgte modeller for mer om dette).

Figur 11: WER for ikke-overlappende tale fordelt på dialekt, nynorsk




Dialektresultater for overlappende tale


Når vi kun ser på materiale med overlapp i Figur 12 og 13 er bildet nok en gang annerledes. Resultatene er dårligere med høyere WER-verdier og spennet mellom best og dårligst dialekt er større, hvilket er forventet. I tillegg peker trøndersk seg ut med dårligere resultater, *openai-whisper-large-v3-turbo* får en særlig forhøyet WER for vestnorsk i bokmål og nynorsk, og *openai-whisper-large-v3* får forhøyet WER for vestnorsk i nynorsk.

De forhøyede WER-verdiene i disse tilfellene skyldes at noen segmenter har spesielt høy WER. Ettersom det overlappende materialet utgjør en liten andel av totalmaterialet for hver dialekt, vil slike enkeltsegmenter trekke gjennomsnittsscoren opp. De dårlige vestnorskresultatene til *openai-whisper-large-v3* og *openai-whisper-large-v3-turbo* skyldes hallusinasjoner der modellen repeterer ett ord mange ganger, f.eks. «se se se se [...]» 222 ganger. Når referansetranskripsjonen kun har 5 ord, fører det til en WER på 4400 %. Vi så at hallusinasjoner var et problem ved OpenAI-modellen i fjor. Modellene gir færre slike hallusinasjoner i år, men *openai-whisper-large-v3-turbo* har produsert ett tilfelle for bokmål og to for nynorsk, og *openai-whisper-large-v3* har produsert ett tilfelle for nynorsk i det overlappende materialet for vestnorsk, hvilket gir de høye WER-verdiene.

Figur 12: WER for overlappende tale fordelt på dialekt, bokmål



Figur 13: WER for overlappende tale fordelt på dialekt, nynorsk




Trøndersk er dialektområdet med minst andel overlappende tale (5 %) i forhold til ikke-overlappende tale (95 %), hvilket betyr at subsettet med overlappende tale er lite og noen få segmenter med høy WER vil ha stor innvirkning på gjennomsnittsscoren. For trøndersk handler ikke de høye WER-verdiene om hallusinasjoner. Det er heller et knippe på 20-30 segmenter med WER mellom 100 % og 300 % som tydelig er vanskelige for mange av modellene. Noen modeller produserer feil transkripsjoner, mens andre gir tomme transkripsjoner. Slike tilfeller finner vi også i det trønderske materialet uten overlapp, men ettersom det utgjør mesteparten av det trønderske materialet har de ikke samme effekt på gjennomsnittsscoren, men forsvinner mer i mengden. Det er ikke åpenbart for oss akkurat hva som er vanskelig med disse trønderske segmentene. Segmentene kommer fra radioprogrammer med opptak av god kvalitet og få forstyrrende elementer annet enn overlappende tale, så det er sannsynligvis en kombinasjon av overlapp, den trønderske dialekten og effekten segmentene har på gjennomsnittsscoren.

Kjønn


WER-verdiene er gjennomgående litt lavere for kvinner enn for menn. Dette er samme resultat som vi så i fjor, så disse resultatene har ikke endret seg nevneverdig. *chirp_2* har størst forskjell mellom kjønnene, på 9 prosentpoeng, mens *openai-whisper-v3-turbo* for nynorsk er modellen med minst forskjell mellom kjønnene på ca. 1 prosentpoeng (se Vedlegg 5).

Som vi skrev i fjor (Solberg et al., 2024, s. 37) er det usikkert hva som er grunnen til kjønnsforskjellene. Det kan hende at dette er en effekt av at kategorien med færrest talere får best score, og det er 161 kvinnelige talere i testsettet mot 199 mannlige talere, men samtidig er taletiden ca. lik (50,7 % kvinner og 49,3 % menn). Vi skrev også i fjor at Feng et al. (2024), og andre de refererer til, har funnet lignende resultater til fordel for kvinner for andre språk.

Figur 14: WER fordelt på kjønn, bokmål



Figur 15: WER fordelt på kjønn, nynorsk



Eksempler fra utvalgte modeller

I denne delen presenterer vi noen eksempler fra modellene som har pekt seg ut enten positivt eller negativt. Vi har sett på NB-Wav2Vec2-modellene ettersom disse får dårligere resultater enn de tilsvarende modellene i fjor. Vi har sett på *openai-whisper-large-v3* ettersom denne har størst forbedring siden i fjor, og vi har sett på eksempler fra *facebook-mms-1b-all* ettersom denne får spesielt dårlige resultater. I alle eksemplene under er transkripsjonene normalisert slik at tegnsetting og stor bokstav er fjernet.

Nb-wav2vec2

Modellene *nb-wav2vec2-1b-nynorsk* og *nb-wav2vec2-1b-bokmål-v2* får høyere WER-verdier i år enn de tilsvarende modellene i fjor. Det er totalt 7260 segmenter i testsettet, og vi har sjekket hvor mange av segmentene som har høyere WER i år enn i fjor. Det er 2765 for nynorskmodellen og 3440 for bokmålsmodellen, hvilket tyder på at et stort antall segmenter har fått litt høyere WER-score, heller enn at noen få segmenter har fått mye høyere WER-score og dratt snittet opp, og eksemplene antyder det samme.

Vi har hentet ut 100 eksempler fra hver av modellene der WER er høyere i år enn i fjor og sett på hva slags feil prediksjonene inneholder, og vi ser at det dukker opp feil i årets prediksjoner som ble transkribert riktig i fjor. Feilene er relativt små, men endrer ordene i en transkripsjon slik at

relativt enkle, vanlige ord blir feil, som f.eks. *gjer* → *gjår* (1), *prøva* → *frøva* (2) og *sommaren* → *somman* (3). Disse feilene speiler muligens uttalen, men gjør altså at transkripsjonen ikke inneholder den korrekte, normerte formen av et ord. For nynorskmodellen kommer disse feilene ofte på toppen av feil knyttet til bokmål-nynorsk-forvirring.

Nynorskeksempler

1. Referanse:

dei gjer seg klare til å lada elbilen på mariero i stavanger som i dag har den dyraste straumprisen i landet

Prediksjon 2024:

dei gjer seg klare til å lada elbilen på marie ro i stavanger som i dag har den dyraste strømprisen i landet

Prediksjon 2025:

dei går seg klare til å lada elbilen på marie ro i stavanger som i dag har den dyraste strømprisen i landet

WER 2024 → 2025:

14,29 % → 19,05 %

2. Referanse:

kan eg prøva eg òg

Prediksjon 2024:

kan eg prøva eg og

Prediksjon 2025:

kan eg frøva eg og

WER 2024 → 2025:

20 % → 40 %

3. Referanse:

dei gjekk på beite om sommaren og nokre av dei som budde på garden gret når slaktebilen kom om hausten

Prediksjon 2024:

dei gjekk på beito~~m~~ somma~~re~~n og nokon av dei som budde på garden gråt når slaktebilen kom om hausten

Prediksjon 2025:

dei gjekk på beito~~m~~ somma~~n~~ og nokon av dei som budde på garden gro~~t~~ når slaktebilen kom om hausten

WER 2024 → 2025:

15 % → 25 %

Bokmålseksempler

4. Referanse:

men det hørtes ut som allikevel det er ting fra den tida som du savner

Prediksjon 2024:

men men det men det høres jo sannelig det er ting fra den tida som du savner

Prediksjon 2025:

men men men det er men det hørtes jo senn lik det er ting fra den tida som du sanner

WER 2024 → 2025:

40 % → 60 %

5. Referanse:

tusen takk skal du ha for at du kom i studio

Prediksjon 2024:

tusen takk skal du ha for at du kom i studio

Prediksjon 2025:

tusen takk skal du ha for at det kommer studio

WER 2024 → 2025:

0 % → 27,27 %

Openai-whisper-large-v3

openai-whisper-large-v3 er modellen som har størst forbedring for alle metrikkene sammenlignet med modellen *openai-whisper-large* som ble testet i fjor, og forskjellen er størst for nynorsk. Vi har hentet ut 100 segmenter som har lavere WER i år enn i fjor for å se nærmere på hva som er forskjellen i transkripsjonene.

En viktig forskjell ved nynorsktranskripsjonene er at den nye modellen har eliminert nonsense-transkripsjoner med lange rekker ikke-latinske tegn, som i (6). Det var så mange som 1184 slike prediksjoner i fjor og det er ingen i år. (Det var, og er, ingen for bokmål). I tillegg er andre hallusinasjoner av typen som er beskrevet under Dialektresultater for overlappende tale (over) kraftig redusert for både bokmål og nynorsk. Dette har åpenbart en positiv effekt på metrikkene.

Når vi ser nærmere på eksemplene ser vi at modellen fortsatt sliter med å transkribere riktig nynorsk. Mye blir bokmål, og WER er fortsatt så høy som 39,69 %, selv om det har gått ned fra 51,87 %. En tendens vi ser er at prediksjoner som inneholdt feil som ville vært feil på begge målformer, nå har en "riktigere" transkripsjon i henhold til bokmålsnormen, og ettersom det er overlapp mellom målformene, blir altså transkripsjonen riktigere nynorsk (7-8). I andre eksempler er transkripsjonen blitt mer ordrett, hvilket fører til bedre WER, men dette er en større tendens for bokmålstranskripsjonene og beskrives nærmere under. Det er med andre ord fortsatt vanskelig å si at modellen håndterer nynorsk godt, med tanke på hvor mye bokmål vi finner i prediksjonene.

For bokmålstranskripsjonene ser det ut til at den forbedrede WER-scoren først og fremst henger sammen med at modellen har gitt en mer ordrett transkripsjon (9-11). Whisper-modellen gir i

Nynorskeksempler

nei nei

[illegible]

nei nei

100 % $\rightarrow$ 0 %

nei eg er det ein ting eg har skjønt så eg skal ikkje peika på nokon

æda en ting ær skall ikke pekk på nunn

er det en ting jeg har skjønnet så skal jeg ikke peke på noen

87,50 % → 56,25 %

men kvifor sluttar dei ikkje då på ekte i staden berre for å ha ei stille slutning

men korfor sluttar dei me ikkje på ekte steden bar for å haje eit stilleslutning

men hvorfor slutter de ikke på ekt i stedet for å ha en stille slutning

64,71 % → 52,94 %

Bokmålseksempler

9. Referanse:

jeg tenker for det første så skal vi ikke fokusere på hva foreldre gjør galt

Prediksjon 2024:

jeg tenker at vi ikke skal fokusere på hva foreldre gjør galt

Prediksjon 2025:

jeg tenker for det første så skal vi ikke fokusere på hva foreldre gjør galt

WER 2024 → 2025:

40 % → 0 %

10. Referanse:

og fortsettelsen på det kan det være for jeg tenker sånn kanskje hun trenger noe å drive med altså hun har jo åpenbart mye tid til overs for det tar jo masse tid

Prediksjon 2024:

og fortsett kan det være kanskje han trenger noe å drive med hun har jo åpenbart mye tid til overs

Prediksjon 2025:

og fortsettelsen på det kan det være kanskje hun trenger noe å drive med altså hun har jo åpenbart mye tid til overs for det tar jo masse tid

WER 2024 → 2025:

45,45 % → 12,12 %

11. Referanse:

altså hun bare plutselig var ikke der

Prediksjon 2024:

hun var plutselig ikke der

Prediksjon 2025:

altså hun bare plutselig var ikke der

WER 2024 → 2025:

42,86 % → 0 %

facebook-mms-1b-all

facebook-mms-1b-all er testet for første gang i år og får de dårligste resultatene for både bokmål og nynorsk. Meta hevder at denne flerspråklige modellen håndterer mer enn 1000 språk, men resultatene og eksemplene taler for seg. Det er ikke mulig å konkludere med at denne modellen gir brukbare transkripsjoner på hverken bokmål eller nynorsk. Ofte består prediksjonene av transkripsjoner som ikke er riktig skriftlig norsk, men det er mulig å se at transkripsjonen gjengir det som ble uttalt (12-13, 15-16). I andre eksempler er prediksjonene tilsynelatende på et annet språk enn norsk (14, 17).

Nynorskeksempler

12. Referanse:

så ganske lik ein sandvolleyballbane eigentleg men med kunstgras og så speler du med tilnærma lik tennisballar og ballen må gå i bakken i graset før han kan gå i veggen

Prediksjon:

de ver ved ganske lik enn sannvorlig v alban egenlegt men med kunstgras og s speler du med tilner om han likk tennesballa og ballen mo go i bakken i grase for angan go i veggen

WER: 70,97 %

13. Referanse:

korleis då

Prediksjon:

voranda

WER: 100 %

14. Referanse:

shit ein kan gjera det her og eg reagerte sånn her på det så då må det jo vera greitt

Prediksjon:

asitmen kanlayorlar o yara yapia tarkalasalam olurur vargi

WER: 100 %

Bokmålseksempler

15. Referanse:

nei jeg er jo egentlig mer misunnelig til de utenfor bergen som fikk lov til å ha nynorsk som hovedmål

Prediksjon:

ne ger j enkleig med binsunlig il det ut po bergen som firk glote ha en ny nosk som hovedmol

WER: 85 %

16. Referanse:

hvorfor må du hjem til 17 mai

Prediksjon:

vor formod du gemtesat amag

WER: 85,71 %

17. Referanse:

det går så tregt framover

Prediksjon:

di gors wat rik vra

WER: 100 %

Oppsummering

Denne rapporten presenterer resultatene av den 2. evalueringen av norske talegjenkjenningssystemer. I årets evaluering har vi testet ti talegjenkjenningsmodeller fra Nasjonalbiblioteket, OpenAI, Google, Microsoft og Meta. Ni av modellene er testet for bokmål og seks er testet for nynorsk – totalt 15 modellevalueringer. Vi har sammenlignet årets modeller både opp mot hverandre og mot fjorårets modeller fra samme aktører for å se hvordan de har utviklet seg.

Årets evaluering bygger på metoden fra forrige evaluering, men med oppdatert utregning av kvalitetsmålene og to nye metrikker: SemDist (semantisk avstand regnet ut med embeddinger fra en BERT-modell) og Aligned Semantic Distance. Rapporten presenterer oppdaterte tall for fjorårets prediksjoner og tall for årets prediksjoner i henhold til årets metode.

De overordnede resultatene viser at de fleste modellene gjør det bedre, i større eller mindre grad, enn tilsvarende modell fra samme aktør i fjor, og tendensene er de samme for alle metrikkene. NB-Whisper-modellene får omtrent samme resultater som i fjor, og *nb-whisper-large-verbatim* er modellen med best resultater for bokmål og nynorsk. *chirp_2* har en svak forbedring fra *usm* i fjor, mens *gcloud* har en større forbedring fra *gcloud-long* i fjor. *gcloud* når allikevel ikke opp til *chirp_2* som er den bedre av de to Google-modellene. Microsoft *azure* presterer også omtrent likt som i fjor, og det ser ikke ut til å være store endringer ved denne modellen. Resultatene er allikevel marginalt bedre. *openai-whisper-large-v3* viser den største forbedringen fra fjorårets modell for både bokmål og nynorsk. *openai-whisper-large-v3-turbo* presterer konsekvent litt dårligere enn *openai-whisper-large-v3*, men den presterer allikevel bedre enn *openai-whisper-large* gjorde i fjor. NB-Wav2Vec2-modellene skiller seg ut ved å få dårligere resultater enn fjorårets modeller, og *facebook-mms-1b-all* får de klart dårligste resultatene.

Når vi ser nærmere på eksempler fra *openai-whisper-large-v3* ser vi at det er flere grunner til de forbedrede resultatene. Først og fremst produserer den færre hallusinasjoner, hvilket påvirket resultatene negativt i fjor, særlig for nynorsk. Dette er en klar forbedring ved modellen (og det er positivt at den nye modellen *openai-whisper-large-v3-turbo* også produserer få hallusinasjoner). Videre ser vi at modellen produserer mer ordrette transkripsjoner, som gir bedre resultater, men ofte kan det være snakk om at en akseptabel ikke-ordrett transkripsjon er erstattet av en mer ordrett transkripsjon. Nynorsktranskripsjonene inneholder mer korrekt nynorsk, men her skjuler det seg også mye bokmål.

Eksempelene fra NB-Wav2Vec2-modellene viser at det er små bokstavendringer i transkripsjonene som gjør tidligere korrekte transkripsjoner til feil transkripsjoner, og disse endringene speiler ofte uttale. Til sist viser eksemplene fra *facebook-mms-1b-all* at disse transkripsjonene ikke er brukbare for hverken bokmål eller nynorsk og blander noen ganger inn andre språk.

Dialektresultatene viser i hovedsak lignende mønstre som i fjor. For bokmålsresultatene er det nordnorsk som får best resultater, mens østnorsk eller sørvestnorsk får dårligst resultater, og modellene der sørvestnorsk kommer dårligst ut – *chirp_2* og *azure* – er de tilsvarende som i fjor.

Vestlandsdialektene får fortsatt bedre nynorskresultater enn de øvrige dialektene, men en endring ved nynorskresultatene siden i fjor er at trøndersk og nordnorsk gjør det bedre relativt til de andre dialektene, mens østnorsk gjør det dårligere relativt sett, og selv om nynorskresultatene på det hele er bedre, er det fortsatt en del bokmålsinnblanding hos de ikke-nynorsknære dialektene.

Forrige evaluering viste at materiale med overlappende tale var utfordrende for modellene. Vi har derfor sett mer på overlappende og ikke-overlappende tale i årets evaluering, og brutt resultatene ned på dialekt. Det er fortsatt en tydelig kvalitetsforskjell mellom de to kategoriene, og overlappende tale får høyere feilrate hos alle modellene. Når vi kun ser på ikke-overlappende tale blir forskjellene mellom dialektene mindre. Østnorsk, som har en stor andel overlappende tale, gjør det forholdsmessig bedre, og sørvestnorsk overtar som dialekten med dårligst resultater. Vi merker oss også at *chirp_2* tilsynelatende håndterer sørvestnorsk like dårlig uavhengig av (ikke-)overlappende tale. Når vi kun ser på overlappende tale er forskjellene mellom dialektene større, og dialektfordelingen endrer seg ved at trøndersk får dårligere resultater og at OpenAI-modellene får spesielt høy WER for vestnorsk. I begge tilfeller er det snakk om at noen segmenter med høy WER trekker scoren opp i et relativt lite subsett av testsettet. For OpenAI-modellene er det snakk om ett eller to segmenter med hallusinasjoner i vestnorsk, mens for trøndersk er det en større andel segmenter som har fått dårlige eller tomme transkripsjoner av flere modeller. Det er vanskelig å peke på noe annet enn kombinasjonen av dialekt og overlappende tale som grunnen til at disse segmentene får høye WER-verdier og trekker scoren opp.

Til slutt ser vi at forskjellen i transkripsjonskvalitet mellom kjønnene som vi så i forrige evaluering fortsatt er gjeldende. Kvinner blir bedre gjenkjent av alle modellene, og disse resultatene er omtrent uendret fra i fjor.

Referanser

Feng, S., Halpern, B. M., Kudina, O., Scharenborg, O. (2024). Towards inclusive automatic speech recognition, *Computer Speech & Language*, 84(101567). doi: <https://doi.org/10.1016/j.csl.2023.101567>

Gulati, A., Qin, J., Chung-Cheng, C., Parmar, N., Zhang, Y., Yu, J., Han, W., Wang, S., Zhang, Z., Wu, Y., Pang, R. (2020) Conformer: Convolution-augmented Transformer for Speech Recognition, *Interspeech 2020*, s. 5036-5040. doi: <https://doi.org/10.48550/arXiv.2005.08100>

Kim, S., Arora, A., Le, D., Yeh, C.-F., Fuegen, C., Kalinli, O., Seltzer, M.L. (2021) Semantic Distance: A New Metric for ASR Performance Analysis Towards Spoken Language Understanding, *Interspeech 2021*, s. 1977-1981. doi: <https://doi.org/10.21437/Interspeech.2021-1929>

de la Rosa, J., Braaten, R. A., Kummervold, P. E., & Wetjen, F. (2023). Boosting Norwegian Automatic Speech Recognition. I *Proceedings of the 24th Nordic Conference on Computational Linguistics (NoDaLiDa)*, s. 555-564. doi: <https://doi.org/10.48550/arXiv.2307.01672>

Rugayan, J., Svendsen, T., Salvi, G. (2022) Semantically Meaningful Metrics for Norwegian ASR Systems, *Interspeech 2022*, s. 2283-2287. doi: <https://doi.org/10.21437/Interspeech.2022-817>

Solberg, P. E., Ortiz, P., Parsons, P., Svendsen, T., & Salvi, G. (2023). Improving generalization of Norwegian ASR with limited linguistic resources. I *Proceedings of LREC 2023*, s. 508-517.

Tilgjengelig på <https://aclanthology.org/2023.nodalida-1.51/> (lest: 23.05.2025)

Solberg, P.E., Røsok, M., Dale, I. L., Lindstad, A. M. (2024) *Status for norsk talegjenkjenning*.

(Nasjonalbiblioteket 01/2024). Oslo: Nasjonalbiblioteket. Tilgjengelig på

https://www.nb.no/sbfil/dok/2024_talegjenkjenning.pdf (lest: 15 april 2025).

Vedlegg

Vedlegg 1:

Tabell 1-3 inneholder resultatene til fjorårets modeller regnet ut med fjorårets og årets metode. Modellene er rangert fra best til verst. Tallene for 2024 er de samme som vi rapporterte i fjor, mens tallene for 2025 er tallene vi gir for fjorårets modeller i årets rapport. Det vi kalte SemDist i fjor er ekvivalent med sBERT SemDist i år.

Tabell 1: WER-resultater for 2024-modeller med gammel og ny utregning

Bokmålsresultater		
Modell (rangert)	WER 2024	WER 2025
nb-whisper-large-verbatim-bokmål	11,89 %	11,87 %
nb-whisper-large-bokmål	18,71 %	18,51 %
usm	20,84 %	20,65 %
nb-wav2vec2-bokmål	22,32 %	22,06 %
azure	24,63 %	24,38 %
openai-whisper-large-bokmål	30,17 %	29,70 %
gcloud-long	30,40 %	30,18 %
nb-whisper-large-semantic-bokmål	31,53 %	31,26 %
Nynorskresultater		
Modell (rangert)	WER 2024	WER 2025
nb-whisper-large-verbatim-nynorsk	21,64 %	20,55 %
nb-whisper-large-nynorsk	29,54 %	28,40 %
nb-whisper-large-semantic-nynorsk	36,18 %	35,14 %
nb-wav2vec2-nynorsk	39,99 %	38,58 %
openai-whisper-large-nynorsk	53,52 %	51,87 %

Tabell 2: CER-resultater for 2024-modeller med gammel og ny utregning

Bokmålsresultater		
Modell (rangert)	CER 2024	CER 2025
nb-whisper-large-verbatim-bokmål	6,50 %	06,40 %
nb-wav2vec2-bokmål	11,95 %	11,71 %
usm	12,89 %	12,61 %
nb-whisper-large-bokmål	13,30 %	13,06 %
azure	16,05 %	15,73 %
openai-whisper-large-bokmål	18,31 %	17,89 %
gcloud-long	22,28 %	21,98 %
nb-whisper-large-semantic-bokmål	24,68 %	24,33 %
Nynorskresultater		
Modell (rangert)	CER 2024	CER 2025
nb-whisper-large-verbatim-nynorsk	12,45 %	10,01 %
nb-whisper-large-nynorsk	20,98 %	18,50 %

nb-wav2vec2-nynorsk	21,62 %	19,04 %
nb-whisper-large-semantic-nynorsk	28,06 %	25,87 %
openai-whisper-large-nynorsk	47,10 %	43,65 %

Tabell 3: (sBERT) SemDist-resultater for 2024-modeller med gammel og ny utregning

Bokmålsresultater			
Modell (rangert)	SemDist 2024	Modell (rangert)	sBERT SemDist 2025
nb-whisper-large-bokmål	0,09	nb-whisper-large-verbatim-bokmål	0,0760
nb-whisper-large-semantic-bokmål	0,11	nb-whisper-large-bokmål	0,0789
nb-whisper-large-verbatim-bokmål	0,12	nb-whisper-large-semantic-bokmål	0,0943
azure	0,17	azure	0,1430
openai-whisper-large-bokmål	0,20	usm	0,1592
nb-wav2vec2-bokmål	0,21	nb-wav2vec2-bokmål	0,1691
usm	0,26	openai-whisper-large-bokmål	0,1820
gcloud-long	0,38	gcloud-long	0,2474
Nynorskresultater			
Modell (rangert)	SemDist 2024	Modell (rangert)	sBERT SemDist 2025
nb-whisper-large-nynorsk	0,11	nb-whisper-large-verbatim-nynorsk	0,0856
nb-whisper-large-semantic-nynorsk	0,11	nb-whisper-large-nynorsk	0,0944
nb-whisper-large-verbatim-nynorsk	0,13	nb-whisper-large-semantic-nynorsk	0,0998
nb-wav2vec2-nynorsk	0,28	nb-wav2vec2-nynorsk	0,2420
openai-whisper-large-nynorsk	0,28	openai-whisper-large-nynorsk	0,2591

Vedlegg 2:

Tabell 4 har en oversikt over hvilke modeller som sammenlignes i søylediagrammene. Gruppene har fått forenklede navn i tilfeller der de individuelle modellene som sammenlignes har forskjellige navn (f.eks. nb-wav2vec2).

Tabell 4: Oversikt over modellgrupper i søylediagrammene

azure		azure, bokmål, 2024
		azure, bokmål, 2025
chirp		usm, bokmål, 2024
		chirp_2, bokmål, 2025
openai-whisper-large		openai-whisper-large-bokmål, 2024
		openai-whisper-large-v3, bokmål, 2025
		openai-whisper-large-nynorsk, 2024
		openai-whisper-large-v3, nynorsk, 2025
nb-whisper-large-verbatim		nb-whisper-large-verbatim-bokmål, 2024

		nb-whisper-large-verbatim, bokmål, 2025
		nb-whisper-large-verbatim-nynorsk, 2024
		nb-whisper-large-verbatim, nynorsk, 2025
gcloud		gcloud-long, bokmål, 2024
		gcloud, bokmål, 2025
nb-wav2vec2		nb-wav2vec2-bokmål, 2024
		nb-wav2vec2-1b-bokmål-v2, 2025
		nb-wav2vec2-nynorsk, 2024
		nb-wav2vec2-2-1b-nynorsk, 2025
nb-whisper-large		nb-whisper-large-bokmål, 2024
		nb-whisper-large, bokmål, 2025
		nb-whisper-large-nynorsk, 2024
		nb-whisper-large, nynorsk, 2025
openai-whisper-large-v3-turbo		openai-whisper-large-v3-turbo, bokmål, 2025
		openai-whisper-large-v3-turbo, nynorsk, 2025
facebook-mms-1b-all		facebook-mms-1b-all, bokmål, 2025
		facebook-mms-1b-all, nynorsk, 2025

Vedlegg 3:

Tabell 5 inneholder en oversikt over andelen materiale per dialekt i testsettet, og andelen overlappende og ikke-overlappende materiale innenfor hver dialekt og for hele testsettet. Andelen er både gitt i timer og prosent.

Tabell 5: Andelen tale per dialekt og per (ikke-)overlappende tale

	Andel av testsettet timer	Andel av testsettet prosent	Overlappende tale timer	Overlappende tale prosent	Ikke-overlappende tale timer	Ikke-overlappende tale prosent
Østnorsk	02:56:36	29,1 %	00:27:09	15,37 %	02:29:26	84,63 %
Vestnorsk	01:57:40	19,39 %	00:11:03	9,39 %	01:46:36	90,61 %
Trøndersk	01:53:14	18,66 %	00:05:27	4,82 %	01:47:46	95,18 %
Nordnorsk	01:47:21	17,69 %	00:06:16	5,84 %	01:41:05	94,16 %
Sørvestnorsk	01:32:04	15,17 %	00:07:40	8,33 %	01:24:23	91,67 %
Hele testsettet	10:06:56	100 %	00:57:36	9,49 %	09:09:20	90,51 %

Vedlegg 4:

Tabell 6 inneholder WER-resultatene til modellene i årets evaluering fordelt på kategoriene overlappende tale og ikke-overlappende tale.

Tabell 6: WER-resultater for overlappende og ikke-overlappende tale

Bokmålsresultater		
Modell	Ikke-overlappende	Overlappende
nb-whisper-large-verbatim	10,49 %	23,12 %

nb-whisper-large	16,57 %	30,11 %
chirp_2	19,04 %	32,32 %
openai-whisper-large-v3	20,32 %	33,81 %
openai-whisper-large-v3-turbo	20,96 %	37,22 %
azure	23,15 %	33,72 %
nb-wav2vec2-1b-bokmål-v2	24,36 %	45,61 %
gcloud	25,78 %	47,75 %
facebook-mms-1b-all	58,41 %	69,20 %
Nynorskresultater		
Modell	Ikke-overlappende	Overlappende
nb-whisper-large-verbatim	18,65 %	30,35 %
nb-whisper-large	25,09 %	38,40 %
openai-whisper-large-v3	38,21 %	51,66 %
nb-wav2vec2-1b-nynorsk	40,33 %	58,20 %
openai-whisper-large-v3-turbo	40,89 %	54,69 %
facebook-mms-1b-all	66,73 %	75,63 %

Vedlegg 5:

Tabell 7 inneholder WER-resultatene til modellene i årets evaluering fordelt på kategoriene kvinne og mann.

Tabell 7: WER-resultater for kvinne og mann

Bokmålsresultater		
Modell	Kvinne	Mann
nb-whisper-large-verbatim	10,26 %	13,50 %
chirp_2	15,73 %	25,38 %
nb-whisper-large	16,50 %	19,70 %
openai-whisper-large-v3	19,85 %	23,93 %
openai-whisper-large-v3-turbo	20,89 %	24,75 %
azure	22,49 %	26,22 %
nb-wav2vec2-1b-bokmål-v2	23,96 %	29,48 %
gcloud	24,84 %	31,64 %
facebook-mms-1b-all	57,29 %	61,97 %
Nynorskresultater		
Modell	WER kvinne	WER mann
nb-whisper-large-verbatim	18,57 %	21,44 %
nb-whisper-large	25,65 %	27,62 %
openai-whisper-large-v3	38,73 %	40,78 %
nb-wav2vec2-1b-nynorsk	39,97 %	44,77 %
openai-whisper-large-v3-turbo	41,81 %	43,14 %
facebook-mms-1b-all	66,48 %	69,06 %